

Movie Review Sentiment Analysis

기말 프로젝트 보고서

과목	딥러닝
학과	통계학과
학번	2022580003
이름	김도원

1. 프로젝트 개요

이번 과제의 목표는 영화 리뷰 phrase 를 입력으로 받아 negative, somewhat negative, neutral, somewhat positive, positive 의 5 개 class 중 하나로 분류하는 것이다. 데이터는 phrase 단위로 제공되기 때문에 단어 sequence 전체를 보고 하나의 sentiment label 을 예측하는 many-to-one 분류 문제로 볼 수 있다. 이 점을 고려하여 RNN 계열 모델인 BiLSTM, BiGRU 와 Attention 구조를 중심으로 실험하였고, 마지막에는 self-attention 기반의 Transformer Encoder 모델도 비교하였다.

기본적인 학습 절차는 데이터 불러오기, 텍스트 전처리, 정수 sequence 변환, GloVe embedding 적용, 모델 학습, validation 성능 확인, Kaggle test prediction 생성 순서로 진행하였다. 모든 모델은 동일한 train-validation split 과 동일한 vocabulary 를 사용하도록 하여 모델 구조와 하이퍼파라미터 변화의 영향을 비교할 수 있게 하였다.

2. 데이터와 전처리

구분	값
Train data	156,060 rows
Test data	66,292 rows
Label class	0, 1, 2, 3, 4 (5 classes)
Train/Validation split	90% / 10%, stratified split
Batch size	128
Embedding	GloVe 100-dimensional vectors
Vocabulary size	16,380
GloVe coverage	약 92.5%
Maximum sequence length	40 tokens




Figure 1. Label 분포와 phrase 길이 분포

Label 분포를 확인한 결과 neutral 에 해당하는 label 2 가 가장 많았고, negative 와 positive 양 끝 class 는 상대적으로 적었다. 이러한 불균형을 고려하여 validation set 을 만들 때 stratify 옵션을 사용하였다. 이렇게 하면 train set 과 validation set 의 label 비율이 거의 비슷하게 유지되어, validation accuracy 를 조금 더 안정적으로 비교할 수 있다.

텍스트 전처리에서는 먼저 모든 문자를 소문자로 바꾸고, 알파벳, 숫자, 기본 문장부호를 제외한 문자를 제거하였다. 그 다음 문장부호 주변에 공백을 넣어 punctuation 이 하나의 token 으로 분리되도록 하였다. Stopwords 제거는 적용하지 않았다. 감성 분석에서는 not, never 와 같은 부정 표현이 문장의 감성을 크게 바꿀 수 있기 때문에, 일반적인 stopwords 제거가 항상 좋은 선택은 아니라고 판단하였다.

문장 길이 분포를 보면 대부분의 phrase 가 비교적 짧았다. 95% 분위수는 22 token, 99% 분위수는 32 token 수준이었기 때문에 maximum sequence length 는 40 으로 설정하였다. 40 보다 긴 sequence 는 앞부분을 기준으로 자르고, 짧은 sequence 는 <PAD> token 으로 padding 하였다. 또한 <UNK> token 을 두어 vocabulary 에 없는 단어를 처리하였다.

Embedding 단계에서는 제공된 GloVe 100 차원 vector 를 사용하였다. Vocabulary 에 있는 단어가 GloVe 파일에 있으면 pretrained vector 를 사용하고, 없는 단어는 random vector 로 초기화하였다. <PAD> token 은 zero vector 로 두어 padding 위치가 의미 있는 단어처럼 사용되지 않게 하였다.

3. 모델 구조

3.1 BiLSTM + Attention

첫 번째 기본 모델은 GloVe embedding layer, bidirectional LSTM layer, attention layer, classifier 로 구성하였다. LSTM 은 RNN 의 장기 의존성 문제를 보완하기 위해 gate 와 cell state 를 사용하는 구조이다. 본 과제의 입력은 단어 sequence 이므로 hidden state 가 시간 순서에 따라 전달되는 RNN 계열 모델이 자연스럽다고 보았다. 또한 앞 단어뿐 아니라 뒤 단어의 문맥도 감성 판단에 영향을 줄 수 있으므로 bidirectional 구조를 사용하였다.

입력 문장은 먼저 정수 index sequence 로 변환된 뒤 GloVe embedding layer 를 통과하여 각 단어가 100 차원 vector 로 표현된다. 이후 BiLSTM layer 는 문장을 앞 방향과 뒤 방향으로 각각 처리하여 각 token 위치마다 양방향 hidden state 를 출력한다. Attention layer 는 이 hidden state 들에 대해 score 를 계산하고 softmax 를 통해 attention weight 를 만든다. 최종적으로 hidden state 들의 weighted sum 을 context vector 로 사용하여 문장 전체의 감성 label 을 예측하였다. 이 구조를 사용한 이유는 영화 리뷰 phrase 에서 감성을 결정하는 단어가 항상 문장의 마지막이나 특정 위치에만 존재하지 않기 때문에, 전체 token 중 중요한 단어에 더 큰 가중치를 줄 필요가 있었기 때문이다.

또한 padding 된 위치가 attention 계산에 영향을 주지 않도록 <PAD> token 위치는 mask 로 처리하였다. 입력 sequence 의 길이를 모두 40 으로 맞추었기 때문에 실제 단어가 아닌 padding 위치도 hidden state 로 계산될 수 있는데, 이 위치까지 attention weight 를 받게 되면 문장 의미와 관계없는 정보가 context vector 에 섞일 수 있다. 따라서 attention score 를 계산한 뒤 padding 위치는 제외하고, 실제 token 들에 대해서만 softmax 를 적용하였다. 마지막 classifier 는 attention 을 통해 얻은 context vector 를 Dropout, Linear, ReLU, Dropout, Linear layer 순서로 통과시켜 5 개 sentiment class 에 대한 logit 을 출력하도록 구성하였다.

3.2 BiGRU + Attention

두 번째 구조는 BiLSTM 에서 recurrent module 만 GRU 로 바꾼 BiGRU + Attention 모델이다. GRU 는 LSTM 보다 구조가 단순한 gated recurrent model 로, reset gate 와 update gate 를 사용한다. 전체 embedding, attention, classifier 구조는 BiLSTM 모델과 최대한 비슷하게 유지하였다. 이렇게 구성하면 LSTM 과 GRU 라는 recurrent module 차이가 성능에 어떤 영향을 주는지 비교할 수 있다.

BiGRU 모델에서도 Attention layer 는 BiLSTM 모델과 동일하게 사용하였다. GRU layer 가 각 token 위치에서 양방향 hidden state 를 출력하면, Attention layer 는 이 hidden state 들 중 감성 분류에 더 중요한 token 에 더 큰 가중치를 부여한다. 이처럼 recurrent module 만 LSTM 에서 GRU 로 바꾸고 나머지 구조를 거의 동일하게 유지한 이유는, 모델 전체를 크게 바꾸기보다 LSTM 과 GRU 의 차이만 비교하기 위해서이다. GRU 는 LSTM 보다 gate 구조가 단순하므로 학습 속도나 일반화 성능에서 차이가 나타날 수

있다고 보았고, 이를 확인하기 위해 기본 BiGRU 모델과 dropout, learning rate 를 조정한 모델을 함께 실험하였다.

3.3 Transformer Encoder

마지막 비교 모델은 Transformer Encoder 기반 모델이다. 이 모델은 GloVe embedding 에 positional encoding 을 더한 뒤 Transformer Encoder layer 를 통과시킨다. RNN 계열 모델과 달리 recurrent 구조를 사용하지 않고 self-attention 을 통해 sequence 내 token 들 사이의 관계를 한 번에 계산한다. 다만 본 실험에서는 제공된 GloVe embedding 을 활용하는 방향에 맞추어, BERT 같은 외부 pretrained 대형 모델은 사용하지 않았다. 대신 GloVe embedding 과 PyTorch 의 Transformer Encoder 를 이용하여 직접 분류 모델을 구성하였다.

Transformer Encoder 모델에서는 단어의 순서 정보를 반영하기 위해 positional encoding 을 embedding 에 더해주었다. Transformer 는 RNN 처럼 hidden state 를 순차적으로 전달하지 않기 때문에, 단어가 문장 내에서 어느 위치에 있는지를 별도로 알려줄 필요가 있다. 이후 Transformer Encoder layer 는 multi-head self-attention 을 이용하여 각 token 이 sequence 내 다른 token 들과 어떤 관계를 가지는지 계산한다. 본 실험에서는 GloVe embedding 의 차원이 100 이므로 embedding dimension 이 attention head 수로 나누어떨어지도록 nhead 를 4 로 설정하였다. Encoder 를 통과한 token representation 들은 Attention pooling 을 통해 하나의 context vector 로 요약한 뒤 classifier 에 입력하였다.

4. 실험 설정

항목	설정
Loss function	CrossEntropyLoss
Optimizer	Adam
Epoch	5
Hidden dimension	256 (BiLSTM/BiGRU)
Number of recurrent layers	2
Classifier	Dropout - Linear - ReLU - Dropout - Linear
Gradient clipping	max_norm = 1.0
Transformer setting	nhead=4, num_layers=2, dim_feedforward=256

하이퍼파라미터 실험은 한 번에 여러 값을 동시에 바꾸기보다, 기본 구조에서 하나의 조건만 바꾸는 방식으로 진행하였다. BiLSTM에서는 dropout 을 0.5 에서 0.6 으로 증가시킨 모델, learning rate 를 $1e-3$ 에서 $5e-4$ 로 낮춘 모델을 비교하였다. BiGRU 에서도 같은 방식으로 기본 모델, dropout 증가 모델, learning rate 감소 모델을 비교하였다. 이 방법을 사용하면 어떤 변경이 성능에 영향을 주었는지 상대적으로 해석하기 쉽다.

5. 학습 결과 시각화

아래 그래프들은 각 모델의 epoch 별 train/validation loss 와 accuracy 를 나타낸다. matplotlib 으로 학습 과정을 시각화하였다.





Figure 2. BiLSTM + Attention 기본 모델의 loss 와 accuracy 변화





Figure 3. BiLSTM + Attention, dropout=0.6 의 loss 와 accuracy 변화





Figure 4. BiLSTM + Attention, lr=5e-4 의 loss 와 accuracy 변화





Figure 5. BiGRU + Attention 기본 모델의 loss 와 accuracy 변화





Figure 6. BiGRU + Attention, dropout=0.6 의 loss 와 accuracy 변화





Figure 7. BiGRU + Attention, lr=5e-4 의 loss 와 accuracy 변화





Figure 8. Transformer Encoder 의 loss 와 accuracy 변화

각 그래프는 모델이 epoch 가 진행되면서 학습 데이터에 점차 적합되는지, 그리고 validation 성능이 어느 시점에서 정체되거나 감소하는지를 확인하기 위한 목적으로 사용하였다.

6. Validation 및 Kaggle score 결과

Version	Model	변경 사항	Best validation accuracy	Kaggle public score
ver1	BiLSTM + Attention	기본 구조, dropout=0.5, lr=1e-3	0.6914	0.65505
ver2	BiLSTM + Attention	dropout=0.6	0.6906	0.65731
ver3	BiLSTM + Attention	lr=5e-4	0.6871	0.65576
ver4	BiGRU + Attention	기본 구조, dropout=0.5, lr=1e-3	0.6878	0.65635
ver5	BiGRU + Attention	dropout=0.6	0.6908	0.65623
ver6	BiGRU + Attention	lr=5e-4	0.6876	0.65323
ver9	Transformer Encoder	self-attention 기반 모델	0.6747	0.64801

Dropout 을 0.5 에서 0.6 으로 높인 것은 모델이 특정 hidden representation 에 과도하게 의존하는 것을 줄이기 위한 실험이었다. Validation accuracy 는 기본 BiLSTM 보다 아주 조금 낮았지만, Kaggle public score 에서는 가장 높은 점수를 기록하였다. 이 결과는 validation set 에서는 약간의 성능 손실이 있었지만, test set 에서는 더 강한 regularization 이 일반화 성능에 도움이 되었을 가능성을 보여준다. 다만 차이가 크지는 않기 때문에 dropout 증가가 항상 성능 향상을 보장한다고 보기는 어렵고, 이번 데이터와 split 에서 test score 가 근소하게 개선된 것으로 해석하였다.

Learning rate 를 5e-4 로 낮춘 실험은 parameter update 폭을 줄여 더 안정적인 학습을 기대한 것이다. 그러나 5 epoch 안에서는 성능 향상이 뚜렷하지 않았다. 이는 learning rate 가 낮아지면서 loss 가 더 천천히 감소하였고, 제한된 epoch 안에서 충분히 수렴하지 못했을 가능성이 있다. 따라서 이번 실험에서는 learning rate 감소보다 dropout 조정이 더 효과적인 선택이었다.

Kaggle public score 기준으로 가장 높은 모델은 ver2 인 BiLSTM + Attention dropout=0.6 모델이었다. Validation accuracy 만 보면 기본 BiLSTM 모델(ver1)이 0.6914 로 가장 높았지만, Kaggle score 는 dropout 을 0.6 으로 높인 ver2 가 0.65731 로 가장 높았다. 두 모델의 validation accuracy 차이는 크지 않았고, test set 에서는 조금 더 강한 dropout 이 일반화에 도움이 된 것으로 해석할 수 있다.

BiGRU 계열에서는 기본 BiGRU 모델(ver4)이 0.65635 로 가장 높았고, dropout=0.6 모델(ver5)도 0.65623 으로 거의 비슷했다. BiGRU 도 validation 기준으로는 dropout=0.6 모델이 0.6908 로 높았지만, Kaggle score 에서는 기본 모델이 근소하게 앞섰다. 이는 validation set 과 Kaggle test set 의 분포가 완전히 동일하지 않기 때문에 생길 수 있는 차이로 보인다.

Transformer Encoder 는 self-attention 을 통해 sequence 내부 token 들 간의 관계를 한 번에 계산할 수 있다는 장점이 있다. 그러나 이번 실험에서는 BERT 와 같은 대형 pretrained Transformer 를 사용한 것이 아니라, GloVe embedding 을 입력으로 하는 비교적 작은 Transformer Encoder 를 직접 학습하였다. Transformer Encoder 모델(ver9)은 validation accuracy 그래프에서 학습이 진행되며 성능이 향상되는 모습을 보였지만, Kaggle score 는 0.64801 로 RNN 계열 모델보다 낮았다. 또한 데이터의 phrase 길이가 대부분 짧았기 때문에, 긴 sequence 에서 token 간 관계를 넓게 반영하는 Transformer 의 장점이 크게 드러나기 어려웠을 수 있다. 반면 BiLSTM 과 BiGRU 는 짧은 sequence 를 순차적으로 처리하면서 양방향 문맥을 반영할 수 있어 이번 task 에서 더 안정적인 성능을 보인 것으로 판단하였다.

Submissions evaluated for final score

All
Successful
Selected
Errors
Public Score ▾

Submission and Description	Private Score ⓘ	Public Score ⓘ	Selected
 Output_Dowon_ver2.csv Complete (after deadline) · 3h ago	0.65731	0.65731	☐
 Output_Dowon_ver4.csv Complete (after deadline) · 4h ago	0.65635	0.65635	☐
 Output_Dowon_ver5.csv Complete (after deadline) · 1h ago	0.65623	0.65623	☐
 Output_Dowon_ver3.csv Complete (after deadline) · 3h ago	0.65576	0.65576	☐
 Output_Dowon_ver1.csv Complete (after deadline) · 6h ago	0.65505	0.65505	☐
 Output_Dowon_ver6.csv Complete (after deadline) · 1h ago	0.65323	0.65323	☐
 Output_Dowon_ver9.csv Complete (after deadline) · now	0.64801	0.64801	☐
 Output_Dowon_ver8.csv Complete (after deadline) · now			☐

Figure 9. Kaggle submission 결과 화면 (public score 기준 정렬, ver8 은 연습용 제출임.)

7. 결과 분석

6 장의 수치 결과를 종합하면, 본 실험에서는 Transformer Encoder 보다 RNN 계열 모델이 더 안정적인 Kaggle score 를 보였다. 이 과제의 phrase 길이는 대부분 짧고, GloVe embedding 을 사용한 비교적 작은 규모의 모델을 학습한 것이므로, BiLSTM 이나 BiGRU 처럼 sequence 를 순차적으로 처리하는 구조가 안정적으로 작동한 것으로 보인다. 특히 bidirectional 구조는 앞쪽과 뒤쪽 문맥을 동시에 반영할 수 있어서 감성 단어와 부정 표현의 위치가 다양한 문장에 적합했다.

BiLSTM 기본 모델은 validation accuracy 가 가장 높았지만, Kaggle score 에서는 dropout=0.6 모델이 가장 좋았다. Dropout 을 높이면 학습 과정에서는 일부 뉴런을 더 많이 비활성화하므로 학습 성능이 약간 낮아질 수 있다. 그러나 test data 에 대해서는 더 강한 regularization 이 일반화에 도움이 되었을 가능성이 있으며, 그 결과 public score 가 근소하게 상승한 것으로 해석할 수 있다.

Learning rate 를 $5e-4$ 로 낮춘 모델들은 두 계열 모두 Kaggle score 가 크게 좋아지지는 않았다. Learning rate 를 낮추면 update 폭이 작아져 학습이 안정될 수 있지만, 5 epoch 라는 제한된 학습 횟수에서는 충분히 수렴하지 못했을 가능성이 있다. 따라서 이번 실험에서는 learning rate 감소보다 dropout 조정이 더 의미 있는 결과를 보였다.

최종적으로 Kaggle public score 를 기준으로 ver2 BiLSTM + Attention dropout=0.6 모델을 가장 좋은 모델로 판단하였다. 다만 validation accuracy 와 Kaggle score 가 항상 같은 순위를 보이지는 않았기 때문에, 최종 모델 선택에서는 validation 결과와 Kaggle public score 를 함께 확인하였다.

다만 이번 실험에는 몇 가지 한계도 있다. 첫째, label 2 에 해당하는 neutral class 의 비중이 크기 때문에 accuracy 만으로는 각 class 별 성능을 모두 설명하기 어렵다. 예를 들어 negative 나 positive 처럼 상대적으로 적은 class 에서의 예측 성능은 전체 accuracy 에 덜 반영될 수 있다. 둘째, 본 실험에서는 class weight 나 oversampling 과 같은 label imbalance 보정 방법은 사용하지 않았다.

모델 구조와 하이퍼파라미터 변화에 따른 차이를 우선 비교하기 위해 동일한 데이터 구성과 동일한 평가 기준을 유지하였다. 셋째, 모든 모델을 5 epoch 기준으로 비교했기 때문에 learning rate가 낮은 모델이나 Transformer Encoder 모델은 더 긴 학습에서 다른 결과를 보일 가능성도 있다. 따라서 본 보고서의 결론은 동일한 실험 조건에서의 상대적 비교 결과로 해석하는 것이 적절하다.

8. 결론

본 프로젝트에서는 영화 리뷰 감성 분석을 위해 GloVe embedding 기반의 BiLSTM + Attention, BiGRU + Attention, Transformer Encoder 모델을 구현하고 비교하였다. 텍스트 전처리에서는 소문자 변환, 기본 문자 정리, punctuation 분리를 적용하였고, 감성 분석에서 중요한 부정 표현을 보존하기 위해 stopwords 제거는 하지 않았다. Sequence는 maximum length 40으로 맞추어 padding과 truncation을 적용하였다.

실험 결과, 가장 높은 Kaggle public score는 BiLSTM + Attention에서 dropout을 0.6으로 증가시킨 ver2 모델의 0.65731이었다. 따라서 최종 제출 모델은 ver2로 판단하였고, 보고서에는 해당 모델의 Kaggle public score를 최종 성능으로 기록하였다. 본 실험을 통해 RNN 계열 모델과 Attention 구조가 phrase-level sentiment classification에서 비교적 안정적인 성능을 보인다는 점을 확인하였다.

참고자료

수업 교안: RNN, LSTM and GRU, Regularization and Generalization, Recent Issues in Deep Learning.

Bo Pang and Lillian Lee. Seeing stars: Exploiting class relationships for sentiment categorization with respect to rating scales. ACL, 2005.